

LAPORAN HASIL PROJECT ANALISIS REGRESI LANJUTAN

Transformasi Respons

Bagaimana Transformasi Respons Dapat Digunakan untuk Memahami atau Memodelkan Konsumsi Energi Peralatan Rumah Secara Tepat, Terukur, dan Dapat Dijelaskan.



Disusun Oleh:

1. Intania Bungan Apui NPM. 140720260013
2. Vinka Marisa Putri NPM. 140720260012

**UNIVERSITAS PADJADJARAN
JATINANGOR
2026**

1. Pendahuluan dan Ruang Lingkup Proyek

Efisiensi energi rumah tangga merupakan pilar strategis dalam pengembangan manajemen energi cerdas (*smart energy management*). Pemodelan statistik yang akurat terhadap pola konsumsi menjadi fondasi utama bagi optimalisasi beban listrik tanpa mengorbankan kenyamanan penghuni. Tantangan utama dalam data ini adalah volatilitas tinggi dan distribusi yang tidak simetris, yang memerlukan pendekatan pemodelan yang lebih canggih daripada regresi linear standar.

Definisi Unit Observasi & Data Analisis ini menggunakan dataset konsumsi energi dari 11 Januari hingga 27 Mei 2016. Unit observasi didefinisikan sebagai satu baris data yang mewakili pengukuran tunggal pada interval median 10 menit (600 detik). Fokus utama adalah variabel respons Appliances (Wh), yang mengukur energi yang dikonsumsi peralatan rumah tangga (di luar lampu) berdasarkan sub-meter energi. Data mencakup kondisi iklim internal di berbagai ruangan serta variabel cuaca eksternal.

Perumusan Masalah & Pertanyaan Utama Penelitian ini bertujuan menjawab: "Bagaimana transformasi respons dapat digunakan untuk memodelkan konsumsi energi peralatan rumah secara tepat, terukur, dan dapat dijelaskan?" Fokus utama adalah mengevaluasi apakah transformasi Box-Cox dapat menstabilkan varians dan meningkatkan validitas inferensi dibandingkan model regresi linear tradisional.

2. Eksplorasi Data Terarah (EDA) dan Kualitas Data

Pemahaman terhadap distribusi awal sangat krusial untuk menentukan strategi transformasi. Kualitas data yang buruk atau adanya nilai nol dapat menghambat transformasi seperti Box-Cox.


Analisis Kualitas Data Berdasarkan pemeriksaan terhadap 19.735 observasi, integritas data ditemukan sangat solid.

Parameter Pemeriksaan	Hasil	Tindakan
<i>Missing Values</i>	0 sel	Tidak perlu imputasi
<i>Duplicate Rows</i>	0 baris	Integritas data terjaga
<i>Negative Values</i>	0 observasi	Konsisten secara fisik
<i>Zero Values</i>	0 observasi	Box-Cox dapat diterapkan langsung

Nilai minimum Appliances adalah 10 Wh. Ketiadaan nilai nol ini memungkinkan transformasi Box-Cox dilakukan tanpa penambahan konstanta semu.

Karakteristik Distribusi Respons Variabel Appliances menunjukkan *mean* sebesar 97,69 Wh, namun *median* hanya sebesar 60 Wh. Perbedaan signifikan ini, didukung oleh nilai *skewness* tinggi (3,39), mengonfirmasi distribusi *heavy-tailed* (condong ke kanan). Pola ini mengindikasikan adanya lonjakan konsumsi energi jangka pendek yang ekstrem di atas penggunaan *baseline*.

Hasil Analisis Korelasi




Gambar 1. Hasil analisis korelasi

Korelasi Linear Cenderung Lemah ($r < 0,25$): seluruh 26 kandidat prediktor memiliki hubungan korelasi linear tergolong lemah terhadap Appliances. Nilai korelasi tertinggi hanya dipegang oleh variabel NSM ($r = 0.217$) dan lights ($r = 0.197$).

Pengaruh Korelasi Negatif Terkuat: Variabel kelembapan luar RH_out menunjukkan korelasi negatif terkuat ($r = -0.152$), artinya saat kelembapan udara di luar meningkat, penggunaan energi Appliances sedikit cenderung menurun.

Seleksi Fitur via Recursive Feature Elimination (RFE)




Gambar 2. Plot Jumlah variabel terhadap RMSE

Seleksi fitur dilakukan menggunakan metode Recursive Feature Elimination (RFE) berbasis regresi linear yang dikombinasikan skema *time-aware cross-validation* untuk mempertimbangkan urutan waktu. Berdasarkan gambar di atas diperoleh 13 prediktor dari 26 kandidat yang efektif menurunkan RMSE. Prediktor terpilih meliputi: T3, RH_2, T1, RH_3, RH_1, T2, T_out, Tdewpoint, T9, T6, RH_9, RH_8, dan T8. Variabel seperti lights dan NSM dieksklusi karena tidak memberikan kontribusi penurunan RMSE yang optimal. Temuan ini menjadi landasan teknis bagi pengembangan model regresi *baseline*.

3. Pemodelan Regresi Baseline dan Justifikasi Transformasi


Model *baseline* pada skala asli (Wh) digunakan sebagai tolok ukur (*benchmark*) untuk mengukur efektivitas intervensi statistik selanjutnya. Model ini menghasilkan *Adjusted R-squared* sebesar 0,1479. Secara inferensial, beberapa koefisien menunjukkan dampak besar; misalnya, setiap kenaikan 1°C pada suhu laundry (T3) diasosiasikan dengan kenaikan konsumsi energi sebesar 28,59 Wh. Namun, interpretasi ini harus diperlakukan dengan hati-hati karena pelanggaran asumsi klasik.

Diagnostik Pelanggaran Asumsi Uji Breusch-Pagan menghasilkan p-value $< 2.2e-16$, menunjukkan adanya heteroskedastisitas kuat yang merusak efisiensi estimator OLS. Selain itu, skor *Durbin-Watson* (DW) yang rendah ($\sim 0,599$) mengindikasikan autokorelasi positif yang kuat. Konsekuensinya, *standard error* (SE) cenderung mengecil secara artifisial, sehingga p-value koefisien menjadi terlalu optimistik (inflasi signifikansi).




Gambar 3. Diagnostik Residual Model A (Baseline): Residual vs Fitted, Q-Q Plot, dan Distribution Plot


Mekanisme Transformasi Box-Cox Melalui *Maximum Likelihood Estimation* (MLE), diperoleh nilai **Lambda optimal sebesar -0,504** dengan interval kepercayaan 95% antara **-0,521 hingga -0,487**. Secara fungsional, transformasi ini berbentuk $\frac{y^\lambda - 1}{\lambda}$ untuk $\lambda \neq 0$, yang secara teoretis sangat efektif untuk data dengan distribusi data energi yang miring ke kanan.



Gambar 4. Perbandingan Residual vs Fitted Model A (Baseline) dan Model B (Box-Cox)



Gambar 5. Perbandingan Q-Q Plot Model A (Baseline) dan Model B (Box-Cox)



Gambar 6. Perbandingan Distribution Plot Model (Baseline) dan Model (Box-Cox)

4. Fit Model Box-Cox dan Diagnostik Komparatif

Tabel Komparatif Diagnostik

Aspek	Model Baseline	Model Box-Cox (Lambda -0.504)
Skala Respons	Wh	Ter-transformasi $y^{(\lambda)} = \frac{y^\lambda - 1}{\lambda} \text{ untuk } \lambda \neq 0$
<i>Adjusted R2</i> (Training)	0,1479	0,2585 (Incomparable)
Breusch-Pagan (p-value)	391,37(< 2e-16)	666,9 (< 2e-16)
Durbin-Watson stat	0.599	0.507
Observasi berpengaruh (%)	5.88	7.03

Analisis Multikolinearitas (VIF) ditemukan multikolinearitas pervasif pada hampir semua variabel iklim dalam ruangan. Nilai VIF melebihi 10 ditemukan pada T6 (24,18), T_out (23,99), T2 (14,98), RH_2 (13,79), T1 (12,47), RH_1 (11,84), dan RH_3 (10,80). Meskipun ini memperlebar SE koefisien, variabel tetap dipertahankan untuk menjaga konsistensi perbandingan antar-model.

5. Validasi Eksternal dan Benchmark Random Forest

Validasi dilakukan dengan *temporal split* (75:25) untuk mencegah *data leakage* temporal yang sering terjadi pada data deret waktu. Hasil *Cross-Validation* (CV) internal pada tahap pelatihan menunjukkan rata-rata RMSE yang stabil: Baseline (98,25) dan Box-Cox (99,32). Variasi RMSE antar-slice menunjukkan bahwa kedua model memiliki stabilitas prediksi yang serupa meskipun menghadapi volatilitas data.

Performa pada Testing Set (Skala Wh)

Model	RMSE	MAE	R2	MAPE (%)
Baseline	84,87	52,12	0,075	63,37%
Box-Cox	84,04	40,69	0,093	39,19%
Random Forest	189,97	162,86	-3,630	240,47%

Meskipun RMSE (yang sensitif terhadap *outlier*) antara *baseline* dan Box-Cox hampir identik, Box-Cox secara drastis menurunkan **MAE (40,69)** dan **MAPE (39,19%)**. Hal ini membuktikan bahwa Box-Cox lebih unggul dalam memprediksi median kondisional dan lebih tangguh terhadap lonjakan konsumsi energi ekstrem dibandingkan *baseline* yang terdistorsi oleh rata-rata (*mean*) pada distribusi *skewed*.

Evaluasi terhadap Benchmark AI (Random Forest), model *Random Forest* menunjukkan kegagalan sistematis dengan RMSE 189,9 dan R² negatif. Berdasarkan ringkasan prediksi, model RF melakukan **over-prediksi masif** dengan rata-rata prediksi 241,49 Wh, sementara rata-rata aktual hanya ~97 Wh. Ini membuktikan bahwa tanpa penanganan struktur temporal dan distribusi yang tepat, algoritma kompleks dapat memberikan hasil yang jauh lebih buruk daripada model regresi yang ditransformasi.

6. Sintesis Temuan dan Rekomendasi Strategis

Implementasi transformasi Box-Cox terbukti menjadi langkah krusial dalam memitigasi anomali statistik pada data energi rumah tangga, memberikan model yang lebih andal dibandingkan skala asli maupun pendekatan AI yang tidak terkalibrasi secara temporal.

Jawaban Pertanyaan Penelitian

- **Kesesuaian Box-Cox:** Transformasi Box-Cox cukup sesuai digunakan karena efektif menangani kemiringan data ekstrem (*skewness* = 3,39). Secara intuitif, transformasi ini "menarik" lonjakan-lonjakan data konsumsi energi yang sangat tinggi agar polanya lebih teratur, sehingga menstabilkan varians dan menekan rata-rata persentase kesalahan relatif (*MAPE* turun dari 63,37% ke 39,19%). Meskipun uji statistik formal heteroskedastisitas (Breusch-Pagan) masih signifikan akibat sensitivitas sampel data yang sangat besar ($n = 19.735$), perbaikan nyata terlihat jelas dari kestabilan residual dan peningkatan akurasi prediksi.
- **Peran AI/Komputasi:** Studi ini membuktikan bahwa algoritma Machine Learning yang kompleks seperti Random Forest dapat mengalami kegagalan prediksi ($R^2 < 0$) jika tidak mampu menangkap struktur urutan waktu (*temporal structure*). Hal ini menjadikan model regresi linear yang ditransformasi sebagai pilihan yang jauh lebih unggul, stabil, dan dapat diandalkan untuk inferensi statistik maupun estimasi energi.
- **Batasan Kesimpulan:** Model regresi ini mengidentifikasi hubungan keterikatan statistik (*asosiasi*) yang kuat antarvariabel cuaca/ruangan terhadap energi, namun tidak boleh ditafsirkan sebagai hubungan sebab-akibat murni (*kausalitas*) tanpa adanya uji eksperimen terkontrol.

Temuan Utama

- **Peningkatan Akurasi:** Transformasi Box-Cox ($\lambda = -0,504$) berhasil menurunkan kesalahan rata-rata absolut (*MAE*) dari 52,13Wh menjadi 40,69Wh (penurunan tingkat kesalahan sebesar 21%). Artinya, estimasi konsumsi energi harian menjadi jauh lebih presisi dan mendekati realita.
- **Stabilitas Model:** Parameter transformasi λ berada pada nilai optimal $-0,504$ (CI 95%: $-0,521$ s.d. $-0,487$). Kestabilan ini juga terbukti konsisten pada rentang $-0,47$ hingga $-0,48$ dalam uji silang berkala (*cross-validation* antar-fold), mengonfirmasi bahwa penyesuaian bentuk data ini didasarkan pada basis bukti data yang kuat (*data-driven*).
- **Pendorong Utama:** Berdasarkan RFE (13 fitur terpilih), **suhu ruangan (T3)** dan **kelembapan udara (RH_1, RH_2, RH_3)** adalah prediktor yang paling mendominasi konsumsi energi.

Rekomendasi Pengembangan

- **Penanganan Autokorelasi:** Karena uji Durbin-Watson mengindikasikan adanya autokorelasi residual, disarankan mencoba model regresi yang mengakomodasi struktur deret waktu, seperti **Generalized Additive Models (GAM)**, **ARIMAX**, atau **Generalized Least Squares (GLS)** dengan struktur *autocorrelation errors* (AR1/ARMA).
- **Integrasi Data Aktivitas:** Faktor penjelas laten seperti jadwal keberadaan penghuni, aktivitas memasak, atau penggunaan perangkat manual saat ini belum terekam oleh sensor. Menambahkan data aktivitas penghuni sangat direkomendasikan untuk menangkap variasi tersembunyi yang saat ini masih tersisa dalam galat residual (*residual error*).